

TUGAS EKSTRAKSI INFORMASI



Mata Kuliah :

Estraksi Informasi

Dosen Pengampu :

Firdaus Solihin, S.Kom., M.Kom

Nama :

Ahmad Hadi Nuryani (240411100135)

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS TRUNOJOYO MADURA

SEPTEMBER

2026

A. Konsep Dasar Information Extraction (IE)

Information Extraction (IE) atau Ekstraksi Informasi adalah cabang dari Natural Language Processing (NLP) dan Artificial Intelligence (AI) yang bertujuan secara otomatis mengekstrak informasi terstruktur dan bermakna dari sekumpulan dokumen atau teks yang tidak terstruktur. Berdasarkan materi video, proses utamanya meliputi pemindaian teks (scanning) untuk mengidentifikasi entitas atau kelas objek tertentu, beserta hubungan (relationship) atau relasi antar entitas tersebut.

Tingkat kesulitan dan akurasi sistem IE sangat bergantung pada domain teksnya. Pada domain yang sangat spesifik dan terbatas (misalnya, sekadar mencari komponen alamat seperti jalan, kota, dan kode pos, atau data cuaca seperti suhu dan kecepatan angin), sistem cenderung memiliki akurasi (knowledge accuracy) yang tinggi. Sebaliknya, saat domain berekspansi menjadi lebih umum (generalized domain) dan berskala raksasa (large scales), informasi bergeser dari yang sifatnya pasti (deterministic) menjadi probabilistik (stochastic). Pada kondisi ini, teknik ekstraksi memerlukan model pembelajaran dan statistik tingkat lanjut yang mampu memahami batasan sintaksis maupun semantik yang jauh lebih kompleks.

B. Pendekatan Penerapan Information Extraction (IE)

Terdapat enam pendekatan utama dalam penerapan Information Extraction sebagaimana dijelaskan dalam materi:

1. Finite State Automata (FSA) / Pendekatan Berbasis Aturan

Penjelasan Video: Sistem yang paling mendasar adalah ekstraksi berbasis atribut, di mana teks dianggap mendeskripsikan satu objek tunggal. FSA merancang template atau kerangka aturan yang kaku menggunakan regular expression. Regular expression ini dibagi menjadi tiga elemen: Prefix (awalan), Target (nilai utama), dan Postfix (akhiran). Untuk teks kompleks yang melibatkan banyak entitas dan relasi, digunakan Cascaded Finite State Transducers. Teks secara berurutan diproses melalui lima tahapan: (1) Tokenization (pemisahan karakter), (2) Complex Word Handling (penanganan kata majemuk), (3) Basic Group Handling (pengelompokan subjek/predikat/objek), (4) Complex Phrase Handling (penggabungan frasa

kompleks), dan (5) Structure Merging (penggabungan seluruh struktur menjadi kalimat utuh logis).

Contoh Sederhana: Mengekstrak harga dari perangkat, misal teks 'IBM Thinkbook 970 with price 399 dollar'. Rule regular expression dirancang dengan prefix 'price', target memfilter angka '[0-9]+', dan postfix kata 'dollar'. Sistem akan secara kaku memotong rentang tersebut.

Kelebihan: Bekerja dengan sangat baik dan efisien pada domain terbatas yang bisa diprediksi strukturnya. Berguna untuk mendesain arsitektur reverse engineering teks terstruktur.

Kekurangan: Akan gagal total bila dihadapkan pada generalized domain atau variasi teks manusia yang sangat dinamis (noisy text). Juga mustahil dan sangat menyita waktu bagi programmer untuk menyusun prioritas semua rule secara hard-code.

Eksplorasi Mendalam: FSA di dunia NLP modern sering direpresentasikan dalam bentuk Named Entity Recognition (NER) berbasis kamus. Kelemahan struktural FSA terletak pada ketiadaan "Generalisasi Kontekstual". Sebagai contoh, jika rule diatur untuk mencari 'Nama - Usia', teks 'Budi, yang kini berumur 20 tahun' tidak akan terdeteksi karena adanya klausa penyela. Karena ketiadaan fleksibilitas ini, biaya pemeliharaan (maintenance) sistem berbasis FSA sangat mahal karena rule harus terus ditambahkan secara manual (hand-crafted rules) oleh pakar linguistik setiap kali ditemukan pola kalimat baru.

2. Probabilistic Model (Hidden Markov Model - HMM)

Penjelasan Video: Menghadapi rumitnya mendefinisikan prioritas pada FSA, HMM hadir sebagai solusi berdasar probabilitas. HMM membagi masalah ke dalam dua tahap: mengobservasi kata-kata yang nampak dari teks (observations), dan menebak urutan status yang tersembunyi (hidden states). Status tersembunyi ini meliputi target informasi yang dicari, prefix, postfix, atau kata latar belakang yang diabaikan. HMM mengukur bobot probabilitas kecocokan teks terhadap suatu entitas target.

Contoh Sederhana: Dari teks pengumuman 'There will be a seminar by Andrew McCallum on Friday'. HMM tidak menggunakan pola regex yang baku. Ia akan menghitung probabilitas bahwa kata 'Andrew McCallum' berpeluang sangat tinggi

sebagai entitas 'Speaker/Pembicara', dan 'Friday' berpeluang tinggi sebagai entitas 'Date/Tanggal' berdasarkan probabilitas transisi historis per kata.

Kelebihan: Model tidak perlu memprogram prioritas kaku. HMM mengurai ambiguitas berdasarkan probabilitas transisi data latih.

Kekurangan: Menyatukan banyak atribut yang saling bergantung menjadi satu model HMM yang besar sangatlah rumit dan komputasinya bisa membengkak.

Eksplorasi Mendalam: HMM merupakan rumpun Model Generatif. Dalam IE, masalah paling fatal pada HMM dikenal dengan "Independence Assumption". Algoritma HMM (misalnya dengan Viterbi Decoding) berasumsi bahwa status kata saat ini hanya bergantung murni pada tepat satu kata di belakangnya (Markov Property). Akibatnya, HMM kehilangan 'Long-Term Context' atau relasi jarak jauh dalam sebuah kalimat panjang. Misalnya, pronoun 'He' di akhir paragraf gagal dihubungkan dengan subjek 'Budi' di awal paragraf.

3. Conditional Random Fields (CRF)

Penjelasan Video: CRF adalah model diskriminatif mutakhir yang dirancang khusus untuk memodelkan distribusi probabilitas bersyarat antara sekumpulan variabel observasi (teks utuh) terhadap variabel target tersembunyi (hidden states). Model ini menyertakan dependensi bersilang antar variabel. Varian paling umum adalah Linear Chain CRF, yang mengevaluasi prediksi pada keseluruhan rangkaian urutan state, bukan hanya biner per-kata.

Contoh Sederhana: Mengekstrak informasi medis. Jika terdapat kalimat kompleks yang menyebut gejala di awal dan penyakit di akhir, CRF tidak menilai tiap kata secara individu. Ia menarik konklusi bahwa urutan A berentetan hingga Z merupakan satu kesatuan struktur berdasar relasi bersyarat secara utuh.

Kelebihan: Jauh lebih canggih dalam menangkap struktur ketergantungan relasi antar variabel tersembunyi (temporal sequence) secara komprehensif.

Kekurangan: Formula normalisasi matematisnya rumit dan kompleks dibandingkan HMM.

Eksplorasi Mendalam: CRF (sebagai Discriminative Model) sukses menambal celah utama HMM yang disebut "Label Bias Problem". Normalisasi pada CRF tidak dilakukan secara sepotong-sepotong per node lokal, melainkan secara global pada seluruh kalimat. Inilah sebabnya CRF sering dipakai sebagai standar industri untuk tugas Sequence Labeling dan Chunking sebelum era Deep Learning. Namun, biaya "Training Time" dari CRF meningkat eksponensial seiring bertambahnya fitur, dan ia tidak mudah mensintesis fitur tersembunyi baru tanpa feature engineering manual dari manusia.

4. Ontology Extraction dari Large Corpora

Penjelasan Video: Bekerja secara independen pada domain berskala raksasa seperti internet atau repositori 100 juta halaman web, pendekatan ini bertujuan merangkai hierarki pengetahuan (kategori dan subkategori ontologi). Karena lautan data sangat acak, metode ini mengandalkan pendekatan High-Precision Templates (template ekstra-kaku berakurasi tinggi). Fokusnya bukanlah mengekstrak satu dokumen dengan sempurna, melainkan mengumpulkan frekuensi statistik secara agregat dari berbagai sumber. Konsep utamanya adalah jika fakta itu benar, maka probabilitas ia muncul pada jutaan teks web akan sangat tinggi.

Contoh Sederhana: Menggunakan template berulang '(Noun Phrase) such as (Noun Phrase)'. Saat ia menyisir miliaran teks, dan seringkali menemukan kalimat 'network protocols such as DNS', sistem secara otomatis menyimpulkan fakta absolut bahwa DNS adalah anak kategori dari protokol jaringan.

Kelebihan: Fleksibilitas tanpa batas antar domain, hasil ekstraksi memiliki kepastian (presisi) nyaris sempurna, tidak butuh campur tangan manusia untuk domain spesifik.

Kekurangan: Sering mengorbankan Recall. Artinya, banyak hubungan atau fakta penting yang terlewatkan apabila ia tidak ditulis dengan gaya bahasa yang persis sama persis dengan template yang diatur.

Eksplorasi Mendalam: Metode ini berakar pada algoritma Hearst Patterns. Karena sangat mengandalkan redudansi internet (data duplication leverage), sistem ini lumpuh jika digunakan pada domain spesifik perusahaan berdata kecil. Namun pada konteks korpus raksasa, metode ini menjadi fondasi awal untuk pembentukan

'Knowledge Graph' masif seperti Google Knowledge Graph atau DBpedia, di mana ia membangun koneksi hierarki taksonomi antar jutaan kata benda tanpa pengawasan manusia (unsupervised).

5. Automated Template Construction

Penjelasan Video: Pada metode ini, model dapat membangun template-nya sendiri hanya dari contoh awal yang sedikit (few examples). Sistem mencari pola awal tersebut di web, menemukan letak awalan, tengah, dan akhir, lalu mengunci struktur baru tersebut menjadi template. Template baru ini digunakan lagi secara otonom untuk memanen data-data lainnya, menciptakan siklus ekstraksi secara otomatis.

Contoh Sederhana: Sistem hanya diberi 5 contoh pasangan 'Penulis, Judul Buku'. Sistem menyisir URL di web dan mendapati ada pola 'buku X ditulis oleh Y', 'X karangan Y'. Pola baru (ditulis oleh, karangan) tersebut disahkan dan dipakai mencari pasangan Penulis dan Buku lainnya di internet.

Kelebihan: Meniadakan kebutuhan programming yang tiada henti karena template lahir secara dinamis, mengungguli otomasi sistem tradisional.

Kekurangan: Sangat rentan dan sensitif terhadap Noise (data kotor). Satu kesalahan kecil pemetaan template di siklus awal akan memicu ledakan kesalahan berantai secara eksponensial di siklus selanjutnya.

Eksplorasi Mendalam: Efek samping mematikan dari algoritma Bootstrap ini di dunia Machine Learning dikenal sebagai "Semantic Drift" (Pergeseran Makna Semantik).

Contohnya, sistem mulai dengan relasi lokasi "Walikota A memimpin Kota B".

Kemudian ia menemukan kalimat "Walikota A mengunjungi Ibukota B". Sistem lalu berasumsi "mengunjungi" adalah relasi lokasi, sehingga ia mengekstrak "Siswa A mengunjungi Sekolah B", yang mana maknanya sudah menyimpang jauh dari relasi "kepemimpinan awal". Solusi utamanya adalah mengimplementasikan "Multiple Discoveries Threshold" dan evaluasi skor Confidence (kepercayaan) tinggi sebelum sebuah template disahkan.

6. Machine Reading

Penjelasan Video: Tahapan evolusi paling puncak dari IE di mana mesin didesain untuk membaca dokumen murni selayaknya nalar manusia membaca bacaan, guna membangun databasenya sendiri. Sistem beroperasi secara "Relation-Independent" (tidak peduli apa jenis hubungan atau entitasnya). Sistem ini memproses semua relasi yang ada secara paralel menggunakan teknik Co-Training (melatih data tidak berlabel menggunakan mesin prediktor) tanpa bergantung pada daftar kamus, noun, atau verb apa pun.

Contoh Sederhana: Contoh produknya adalah TextRunner. Ia menggunakan template sintaksis yang mencakup 95% gaya penyampaian relasi dalam tata bahasa Inggris (seperti relasi Subjek -> Predikat/Kata Kerja Penghubung -> Objek). TextRunner lalu mengekstrak miliaran fakta paralel tanpa diberitahu relasi apa yang sedang dicarinya.

Kelebihan: Solusi pamungkas untuk ekstraksi open domain skala masif yang meminimalisir keterlibatan manusia.

Kekurangan: Membutuhkan infrastruktur sumber daya komputasi dan Input/Output (I/O) raksasa, karena beban memproses jutaan halaman tak terstruktur membutuhkan memori dan CPU luar biasa.

Eksplorasi Mendalam: Machine Reading yang diwujudkan dalam sistem Open Information Extraction (OpenIE), sering kali mendatangkan masalah baru bernama "Entity Resolution" atau Redundansi Fakta. Karena ia murni memetakan apa yang tertulis di teks (Schema-less), ia akan mengekstrak fakta "Microsoft diakuisisi Github" dan "Github dibeli Microsoft" sebagai dua baris database yang terpisah, padahal semantiknya sama. Inilah tantangan utama era OpenIE, yakni mengawinkan hasil bacaan mesin tersebut dengan logika penalaran silang agar fakta tidak berlipat ganda.